Latihan Responsi

2210512015 - Deni Permana

2024-11-16

Latihan Responsi

Kerjakan soal-soal berikut dengan teliti!

Import Library dan Dataset

1. Import Library (5 poin)

Library yang dibutuhkan adalah tidyverse, tidymodels, danhere.

```
library(tidyverse)
```

library(tidymodels)

```
library(here)
```

here() starts at E:/PMM JOGJA/Prak Data Science/Prak-DS-DP-UPNVYK-2024

2. Import Dataset (5 poin)

Import dataset airquality1.csv dan airquality2.csv dengan menggunakan library here, lalu tampilkan 10

```
data pertama.
# airquality1.csv
airquality1 <- read_csv(here("Pertemuan 9/datasetP9/airquality1.csv"))</pre>
## Rows: 153 Columns: 4
## Delimiter: ","
## dbl (4): X, Ozone, Solar.R, Wind
## i Use 'spec()' to retrieve the full column specification for this data.
## i Specify the column types or set 'show_col_types = FALSE' to quiet this message.
head(airquality1, 10)
## # A tibble: 10 x 4
##
        X Ozone Solar.R Wind
##
    <dbl> <dbl> <dbl> <dbl> <
## 1
       1
           41
                 190 7.4
## 2
       2 36
                 118 8
## 3
       3 12
                 149 12.6
          18
                 313 11.5
## 4
       4
## 5
      5 NA
                 NA 14.3
                 NA 14.9
## 6
      6 28
## 7
       7 23
                 299 8.6
## 8
      8 19
                 99 13.8
## 9
       9
                 19 20.1
           8
## 10
     10 NA
                194 8.6
# airquality2.csv
airquality2 <- read_csv(here("Pertemuan 9/datasetP9/airquality2.csv"))</pre>
## Rows: 153 Columns: 4
## Delimiter: ","
## dbl (4): X, Temp, Month, Day
## i Use 'spec()' to retrieve the full column specification for this data.
## i Specify the column types or set 'show_col_types = FALSE' to quiet this message.
head(airquality2, 10)
```

```
## # A tibble: 10 x 4
##
           X Temp Month
                              Day
       <dbl> <dbl> <dbl> <dbl> <
##
    1
                 67
                         5
##
           1
                                1
##
    2
           2
                 72
                         5
                                2
##
    3
           3
                 74
                         5
                                3
##
    4
           4
                 62
                         5
                                4
                         5
##
    5
           5
                 56
                                5
##
    6
           6
                 66
                         5
                                6
##
    7
           7
                 65
                         5
                                7
##
    8
           8
                 59
                         5
                                8
                         5
                                9
##
    9
           9
                 61
                 69
                         5
## 10
          10
                               10
```

Data Preprocessing

3. Data Imputation (15 poin)

Dari soal sebelumnya, dapat dilihat bahwa dataset airquality1 memiliki nilai N/A pada beberapa kolom. Hapus nilai N/A atau lakukan imputasi data sederhana untuk mengisi nilai N/A, lalu tampilkan 10 data pertama.

```
# Hapus N/A
airquality1 <- na.omit(airquality1)
head(airquality1, 10)</pre>
```

```
## # A tibble: 10 x 4
##
          X Ozone Solar.R Wind
##
      <dbl> <dbl>
                      <dbl> <dbl>
##
   1
          1
                41
                        190
                               7.4
##
    2
          2
                36
                        118
                               8
    3
          3
##
                12
                        149
                             12.6
##
    4
          4
                18
                        313
                             11.5
##
    5
          7
                23
                        299
                              8.6
                19
                         99
                             13.8
##
    6
          8
##
    7
          9
                 8
                         19
                             20.1
##
    8
          12
                16
                        256
                               9.7
##
    9
          13
                11
                        290
                               9.2
                        274 10.9
          14
## 10
                14
```

4. Joining Table (10 poin)

Perhatikan dataset airquality1 dan airquality2, ada satu kolom yang sama dari kedua dataset tersebut. Gunakan kolom tersebut untuk menyatukan kedua dataset ke dalam variabel baru bernama airquality. Tampilkan 6 data terakhirnya.

```
library(dplyr)
airquality <- inner_join(airquality1, airquality2, by = "X")
tail(airquality)</pre>
```

```
## # A tibble: 6 x 7
          X Ozone Solar.R Wind Temp Month
##
                                                  Day
     <dbl> <dbl>
                     <dbl> <dbl> <dbl> <dbl> <dbl> <
##
                7
                             10.3
## 1
       147
                         49
                                      69
                                              9
                                                    24
## 2
       148
               14
                         20
                             16.6
                                      63
                                              9
                                                    25
## 3
               30
                       193
                              6.9
                                      70
                                              9
                                                    26
       149
## 4
                             14.3
                                                    28
       151
               14
                       191
                                      75
## 5
       152
               18
                       131
                              8
                                      76
                                              9
                                                    29
## 6
       153
               20
                       223
                             11.5
                                      68
                                                    30
```

5. Pemilihan Kolom (10 poin)

Buat kolom baru bernama Date yang menyimpan kombinasi tanggal dari kolom Month dan Day dengan format yyyy-MM-dd (tahun = 1973). Gunakan fungsi paste untuk menggabungkan string dan fungsi as.POSIXct untuk mengubah string menjadi tanggal. Manfaatkan fungsi help sebaik-baiknya.

```
airquality$Date <- as.POSIXct(paste(1973, airquality$Month, airquality$Day, sep = "-"), format = "%Y-%m head(airquality)
```

```
## # A tibble: 6 x 8
##
         X Ozone Solar.R Wind
                                 Temp Month
                                               Day Date
##
     <dbl> <dbl>
                    <dbl> <dbl>
                                 <dbl> <dbl> <dttm>
## 1
         1
               41
                      190
                            7.4
                                    67
                                           5
                                                  1 1973-05-01 00:00:00
         2
## 2
                                    72
                                           5
                                                  2 1973-05-02 00:00:00
               36
                      118
                            8
## 3
                                                  3 1973-05-03 00:00:00
         3
               12
                      149
                           12.6
                                    74
                                           5
         4
                                    62
                                                  4 1973-05-04 00:00:00
## 4
               18
                      313
                           11.5
                                           5
## 5
         7
               23
                      299
                            8.6
                                    65
                                           5
                                                 7 1973-05-07 00:00:00
## 6
         8
               19
                       99
                           13.8
                                    59
                                           5
                                                  8 1973-05-08 00:00:00
```

Setelah itu, buang kolom X, Day, dan Month yang tidak akan digunakan untuk membuat model. Kemudian, ubah nama kolom Solar.R menjadi Solar Radiation. Gunakan operator pipeline.

```
airquality <- airquality %>%
  select(-X, -Day, -Month) %>%
  rename(Solar_Radiation = Solar.R)

head(airquality)
```

```
## # A tibble: 6 x 5
##
     Ozone Solar_Radiation Wind Temp Date
##
     <dbl>
                     <dbl> <dbl> <dttm>
## 1
        41
                       190
                             7.4
                                     67 1973-05-01 00:00:00
## 2
        36
                       118
                             8
                                     72 1973-05-02 00:00:00
## 3
        12
                       149
                            12.6
                                    74 1973-05-03 00:00:00
## 4
                       313 11.5
                                    62 1973-05-04 00:00:00
        18
## 5
        23
                       299
                             8.6
                                     65 1973-05-07 00:00:00
## 6
        19
                        99
                           13.8
                                    59 1973-05-08 00:00:00
```

Data Visualization

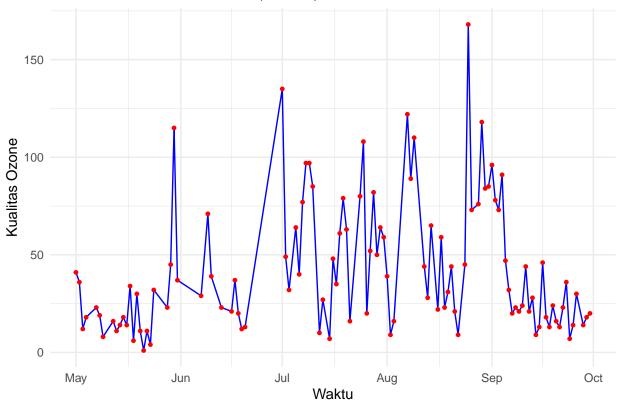
6. Perubahan Kualitas Udara (10 poin)

Gambarkan perubahan kualitas udara (Ozone) setiap harinya dengan menggunakan ggplot2. Kombinasikan 2 jenis geom yang sesuai dengan data yang ada.

```
library(ggplot2)

ggplot(
  data = airquality,
  aes(
    x = Date,
    y = Ozone)
) + geom_line(color = "blue") +
  geom_point(color = "red", size = 1) +
  labs(title = "Perubahan Kualitas Udara (Ozone)",
    x = "Waktu",
    y = "Kualitas Ozone") +
  theme_minimal()
```

Perubahan Kualitas Udara (Ozone)



Data Modelling

7. Scaling Data (5 poin)

Variabel pada dataset ini memiliki range yang berbeda-beda. Lakukan scaling agar berada di range yang sama.

```
library(scales)
airquality_scaled <- airquality %>%
  mutate(across(c(Ozone, Solar_Radiation, Wind), ~ rescale(.)))
head(airquality_scaled, 5)
## # A tibble: 5 x 5
```

```
##
     Ozone Solar_Radiation Wind Temp Date
                    <dbl> <dbl> <dttm>
##
## 1 0.240
                    0.560 0.277
                                 67 1973-05-01 00:00:00
## 2 0.210
                   0.339 0.310
                                 72 1973-05-02 00:00:00
## 3 0.0659
                   0.434 0.560 74 1973-05-03 00:00:00
## 4 0.102
                    0.936 0.5
                                 62 1973-05-04 00:00:00
## 5 0.132
                    0.893 0.342 65 1973-05-07 00:00:00
```

8. Data Splitting (5 poin)

Bagi dataset untuk training dan testing dengan proporsi training 80%. Pastikan dataset diacak sebelum dibagi, dan pastikan hasil acak akan tetap konsisten walaupun dijalankan berkali-kali dari perangkat berbeda sekalipun.

```
set.seed(125)

data_split <- initial_split(airquality_scaled, prop = 0.8)
airquality_train <- training(data_split)
airquality_test <- testing(data_split)
head(airquality_train, 5)</pre>
```

```
## # A tibble: 5 x 5
     Ozone Solar_Radiation
##
                          Wind Temp Date
##
     <dbl> <dbl> <dbl> <dttm>
## 1 0.216
                    0.847 1
                                   72 1973-06-17 00:00:00
## 2 0.0359
                    0.128 0.435
                                   69 1973-09-24 00:00:00
## 3 0.725
                   0.758 0.0924
                                   89 1973-08-07 00:00:00
## 4 0.180
                    0.725 0.467
                                   78 1973-08-19 00:00:00
## 5 0.216
                    0.832 0.277
                                 76 1973-05-31 00:00:00
```

```
head(airquality_test, 5)
```

```
## # A tibble: 5 x 5
## Ozone Solar_Radiation Wind Temp Date
## <dbl> <dbl> <dbl> <dttm>
```

9. Buat Resep (15 poin)

Buat resep untuk training data. Tentukan 3 variabel yang menjadi prediktor dan 1 variabel yang menjadi outcome. Biarkan variabel Date sebagai ID.

```
airquality_resep <- recipe(Ozone ~ Solar_Radiation + Wind + Temp, data = airquality_train) %>%
    step_normalize(all_predictors())
airquality_train_prepped <- prep(airquality_resep, training = airquality_train)
summary(airquality_resep)
## # A tibble: 4 x 4</pre>
```

```
##
   variable
                    type
                               role
                                         source
     <chr>
                     t>
                               <chr>
                                         <chr>>
## 1 Solar_Radiation <chr [2] > predictor original
## 2 Wind
                    <chr [2]> predictor original
## 3 Temp
                     <chr [2] > predictor original
## 4 Ozone
                     <chr [2] > outcome
                                         original
```

summary(airquality_train_prepped)

```
## # A tibble: 4 x 4
##
   variable
                            role
                                      source
                   type
    <chr>
                   st>
                            <chr>
                                      <chr>>
## 1 Solar_Radiation <chr [2]> predictor original
## 2 Wind <chr [2]> predictor original
## 3 Temp
                   <chr [2]> predictor original
## 4 Ozone
                   <chr [2] > outcome
                                      original
```

10. Terapkan Resep (5 poin)

Terapkan resep yang sudah dibuat ke data training dan testing.

```
# airquality_training
airquality_train_processed <- bake(airquality_train_prepped, new_data = airquality_train)
head(airquality_train_processed, 5)</pre>
```

```
## # A tibble: 5 x 4
    Solar_Radiation
                               Temp Ozone
##
                     Wind
              <dbl> <dbl>
                              <dbl> <dbl>
## 1
                     3.05 -0.635
                                    0.216
              1.04
## 2
             -1.54
                     0.121 -0.950
                                    0.0359
              0.720 -1.66 1.15
## 3
                                    0.725
## 4
              0.599 0.291 -0.00477 0.180
              0.984 -0.697 -0.215 0.216
## 5
```

```
# airquality_testing
airquality_test_processed <- bake(airquality_train_prepped, new_data = airquality_test)
head(airquality_test_processed, 5)</pre>
```

```
## # A tibble: 5 x 4
    Solar_Radiation
                   Wind
                           Temp Ozone
##
             <dbl> <dbl> <dbl> <dbl>
## 1
           0.00637 -0.697 -1.16 0.240
## 2
          1.20
                  -0.358 -1.37 0.132
## 3
           -0.993
                    1.11 -2.00 0.108
## 4
           0.929
                  0.291 -1.05 0.0778
## 5
           1.43 1.90 -0.530 0.0599
```

11. Training Model (10 poin)

Training model berdasarkan data yang sudah diolah.

```
hasil_model <- linear_reg() %>%
  set_engine("lm")

airquality_trained_model <- hasil_model %>%
  fit(Ozone ~ Solar_Radiation + Wind + Temp, data = airquality_train_processed)

summary(hasil_model)
```

```
##
                         Length Class
                                          Mode
## args
                                -none-
                                          list
## eng_args
                          0
                                 quosures list
## mode
                          1
                                          character
                                 -none-
## user_specified_mode
                          1
                                 -none-
                                          logical
                          0
                                          NULL
## method
                                 -none-
## engine
                          1
                                          character
                                 -none-
## user_specified_engine 1
                                -none-
                                          logical
```

```
cat("\n")
```

summary(airquality_trained_model)

```
Mode
##
                Length Class
                                   NULL
## lvl
                        -none-
## spec
                 7
                       linear_reg list
## fit
                12
                                   list
## preproc
                 1
                       -none-
                                   list
## elapsed
                 1
                        -none-
                                   list
## censor_probs 0
                       -none-
                                   list
```

12. Evaluasi Model (5 poin)

Evaluasi performa model menggunakan data testing (performanya jelek juga gapapa)

```
# Evaluasi performa model menggunakan data testing
airquality_predictions <- predict(airquality_trained_model, new_data = airquality_test_processed)</pre>
# Menghitung evaluasi metrik (misalnya RMSE)
library(yardstick)
airquality_results <- airquality_test_processed %>%
 bind_cols(airquality_predictions) %>%
 metrics(truth = Ozone, estimate = .pred)
print(airquality_results)
## # A tibble: 3 x 3
    .metric .estimator .estimate
##
                           <dbl>
##
   <chr> <chr>
                         0.162
## 1 rmse standard
## 2 rsq standard
                         0.547
## 3 mae
           standard
                           0.102
```